Open in Colab

Contexto y definición del problema

Contexto:
La farmacéutica colombiana más grande del país basa una parte significativa de su estrategia de comunicación en la _*visita médica*_. Este proceso consiste en que representantes visitan a profesionales de la salud para ofrecerles un portafolio de productos acorde con su especialidad, además de proporcionar muestras médicas para que puedan ser utilizadas con sus pacientes y evaluar su eficacia.

Sin embargo, actualmente se identifican deficiencias en la planificación de la producción de estas muestras médicas. La producción no logra satisfacer la demanda, lo que obliga a la empresa a utilizar productos destinados para venta comercial como sustituto de las muestras médicas. Este desbalance genera inconvenientes operativos y afecta la disponibilidad de productos para su comercialización.

Se cuenta con: La empresa proporciona un conjunto de datos que contiene información real sobre:

1. Las muestras médicas fabricadas específicamente para este propósito.
2. Los productos de venta comercial que se han utilizado como sustituto de las muestras médicas.

La diferenciación de estos dos grupos puede realizarse mediante un *flag* y los códigos únicos de los artículos de muestra médica y venta comercial, que son distintos.

Problema general: Producción insuficiente de muestras médicas para cubrir la demanda del laboratorio en Colombia.

A partir del análisis de los datos históricos despachados, incluyendo muestras médicas y no médicas, de los últimos cinco años (2019-2023), es posible aplicar técnicas de modelado predictivo para estimar la demanda mensual de unidades a producir en 2024. Esto permitirá garantizar un inventario suficiente de muestras médicas y mejorar la eficiencia en la planificación.

Metodología propuesta

Basándonos en los conceptos aprendidos en la clase de Gestión estratégica, se propone la siguiente forma de abordar el problema:

1. Dado el Contexto anterior, definir el **objetivo general y específicos** de este proyecto con el cliente.
2. Realizar un **análisis exploratorio de los datos** entregados por el cliente.
3. Seleccionar los **artículos relevantes** que generan mas pérdida para el cliente.
4. Definir cuales son los mejores **modelos de Machine **Learning** que se pueden aplicar a los datos para resolver el problema.

5. Aplicar el **entrenamiento** de los modelos seleccionados.
6. Realizar **pruebas y calcular métricas de desempeño**.
7. Concluir

Objetivos

En conjunto con el cliente y usuario experto en los datos, se concluyó que podemos establecer como Objetivo General y Específico lo siguiente:

Objetivo General: Optimizar la producción de muestras médicas mediante la aplicación de soluciones de ciencia de datos, con el objetivo de reducir el uso de artículos comerciales y garantizar la disponibilidad continua de estos para los clientes del laboratorio.

Objetivos Específicos:

1. Pronosticar para el 2025 la Demanda de muestras médicas para el laboratorio.
2. Identificar cual es el mejor modelo para pronosticar cada artículo

Análisis exploratorio

In [39]:
```
# Cargue de datos y definición de librerías
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
"""
from statsmodels.tsa.seasonal import seasonal_decompose
from statsmodels.tsa.seasonal import STL


"""

# Llamado desde Google Drive
# from google.colab import drive
# drive.mount('/content/drive')

df = pd.read_csv('D:\Gestión estratégica I\Proyecto final\Entrega 2\datos\Base_Plana_mm.csv', se
df.head(5)      # Visualización de los primeros 5 registros
```

Out[39]:

	ANO	MES	PERIODO	ID_ESCENARIO	ESCENARIO	ID_PAIS_ORIGEN	PAIS_ORIGEN	ID_PAIS_DESTINO
0	2019	1	201901	0	real	90	COLOMBIA	28
1	2019	1	201901	0	real	90	COLOMBIA	28
2	2019	1	201901	0	real	90	COLOMBIA	28
3	2019	1	201901	0	real	90	COLOMBIA	28
4	2019	1	201901	0	real	90	COLOMBIA	28

5 rows × 23 columns

Al validar los datos, se observa que:

- Se cuenta con datos numéricos y categóricos a nivel de Mes, Pais origen, País destino, artículo, Muestra médica (flag), factor comercial inventario, concepto.¨
- En el Dataset entregado existen más Paises que el Paìs objetivo.
- Existen campos como Muestra médica (flag), factor comercial inventario, concepto que no son fáciles de entender.

Procedemos a estudiar esos campos para entender mejor que representan en el Dataset

In [40]:
```
print(f"Combinaciones de PAIS_ORIGEN y PAIS_DESTINO: \n{df[['PAIS_ORIGEN', 'PAIS_DESTINO']].drop_
print(f"Valores únicos de MMEDICA: \n{df['MMEDICA'].unique()}\n")
print(f"Valores únicos de INVENTARIO: \n{df['INVENTARIO'].unique()}\n")
print(f"Combinaciones de MMEDICA y INVENTARIO: \n{df[['MMEDICA', 'INVENTARIO']].drop_duplicates(
print(f"Valores únicos de CPTO: \n{df['CPTO'].drop_duplicates()}\n")
```

```
Combinaciones de PAIS_ORIGEN y PAIS_DESTINO:
     PAIS_ORIGEN    PAIS_DESTINO
0       COLOMBIA     EL SALVADOR
8       COLOMBIA        COLOMBIA
103     COLOMBIA       GUATEMALA
594     COLOMBIA          PANAMÁ
962     COLOMBIA         ECUADOR
1300    COLOMBIA          MEXICO
1674    COLOMBIA      COSTA RICA
2802    COLOMBIA    R.DOMINICANA
3968    COLOMBIA        HONDURAS
6172    COLOMBIA       NICARAGUA
9330    COLOMBIA  ESTADOS UNIDOS

Valores únicos de MMEDICA:
['No' 'Si']

Valores únicos de INVENTARIO:
['SALIDA' 'OTRO']

Combinaciones de MMEDICA y INVENTARIO:
    MMEDICA INVENTARIO
0        No     SALIDA
5        Si     SALIDA
76       No       OTRO
395      Si       OTRO

Valores únicos de CPTO:
0     056-Sal. cargo a gastos
76    145-Ent.Cambio codigo
82    156-ENTRADA POR CONSUMO
Name: CPTO, dtype: object
```

Descripción de los campos

En compañía del Usuario Lider se pudo entender lo siguiente:

- *PERIODO* : Variable numerica discreta,es la fecha en formato año mes (YYYYMM)
- *PAIS_ORIGEN* : Variable categórica nominal, que identifica al país donde se fabrica el producto.
- *PAIS_DESTINO* : Variable categórica nominal, que identifica al país donde se despacha el producto.
- *NEGOCIO* : Variable categórica nominal que identifica el **negocio** al que hace parte el producto.
- *LINEA* : Variable categórica nominal que identifica la **línea** al que hace parte el producto (un negocio tiene muchas líneas pero cada línea corresponde a un único negocio).
- *MARCA* : Variable categórica nominal que identifica la **marca** al que hace parte el producto (una línea tiene muchas marcas pero cada marca corresponde a una única línea).
- *ARTICULO* : Variable categórica nominal que identifica el artículo (SKU).
- *MMEDICA* : Variable categórica nominal que define si el artículo es muestra médica o articulo comercial.
- *INVENTARIO* : Variable categórica nominal que define si el artículo fue una salida o una devolución.
- *CPTO* : Detalle del Inventario.
- *FACTOR_CIAL* : Variable numérica continua que se ututliza para convertir las unidades comerciales a unidades estadísticas (UE = UC * FACTOR_CIAL)
- *UE* : Variable numérica continua que especifica las unidadades que contiene una unidad comercial. Por ejemplo: un sobre con diez tabletas, UC = 1, UE = 10, FACTOR_CIAL = 10

- *UC* : Variable numérica discreta que corresponde a la unidad comercial que se entrega al público. (**ESTA ES LA UNIDAD QUE SE FABRICA**)

Puesto que hay Campos que no suman al análisis y Paises que no son foco de estudio, se decide filtrar el Dataset en filas y columnas dejando la información de interés

In [41]:
```
# Filtrar el DataFrame para PAIS_DESTINO = 'COLOMBIA' y seleccionar las columnas especificadas
df = df[df['PAIS_DESTINO'] == 'COLOMBIA'][['PERIODO', 'NEGOCIO', 'LINEA', 'MARCA', 'ARTICULO', 'I
df = df.groupby(['PERIODO', 'NEGOCIO', 'LINEA', 'MARCA', 'ARTICULO', 'MMEDICA'], as_index=False)
df.rename(columns={'UC': 'UNIDADES COMERCIALES'}, inplace=True)
df
```

Out[41]:

	PERIODO	NEGOCIO	LINEA	MARCA	ARTICULO	MMEDICA	UNI COMER
0	201901	ADITIVOS LAVADO	CloroxQuitamancPolvo	Cojín	CLOROX RBULTRAQUITAMANCHA 900G	No	
1	201901	ADITIVOS LAVADO	CloroxRquitamanchLiq	Botella	CLOROX ROPA COLOR 450ML	No	
2	201901	ADITIVOS LAVADO	CloroxRquitamanchLiq	Cojín	CLOROXCOJIN ROPA COL.VIVOS375c	No	
3	201901	ADITIVOS LAVADO	LimpidoRQuitamancLiq	Botella	LIM ROPACOLO 450+LIM REG 460	No	
4	201901	ADITIVOS LAVADO	LimpidoRQuitamancLiq	Botella	LIMPIDO ROPA COLOR X1000ML	No	
...	...	...	...	...	...	...	
64681	202412	ÉTICOS TQ	Tracto Digestivo	IBS Biotic	IBS BIOTIC	No	
64682	202412	ÉTICOS TQ	Tracto Digestivo	Moviprost 24MCG	MOVIPROST 24 MCG	No	
64683	202412	ÉTICOS TQ	Tracto Digestivo	Moviprost 8MCG	MOVIPROST 8 MCG	No	
64684	202412	ÉTICOS TQ	Tracto Digestivo	Pangetan	PANGETAN NF X2MG TABLETAS	No	
64685	202412	ÉTICOS TQ	Urológica	Bladuril	BLADURIL 200MG TAB.	No	

64686 rows × 7 columns

Análisis de estructura

In [42]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 64686 entries, 0 to 64685
Data columns (total 7 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   PERIODO               64686 non-null  int64
 1   NEGOCIO               64686 non-null  object
 2   LINEA                 64686 non-null  object
 3   MARCA                 64686 non-null  object
 4   ARTICULO              64686 non-null  object
 5   MMEDICA               64686 non-null  object
 6   UNIDADES COMERCIALES  64686 non-null  int64
dtypes: int64(2), object(5)
memory usage: 3.5+ MB
```

El conjunto de datos acotado contiene 64.686 observaciones y 12 variables. Las variables "NEGOCIO", "LINEA", "MARCA", "ARTICULO" y "MMEDICA" son categóricas y no están codificadas numéricamente. "UNIDADES COMERCIALES" es una variable numéricas continua y "PERIODO" una variable nùmerica discreta.

Cada columna corresponde a la descripción previamente proporcionada. La variable objetivo es **"UNIDADES COMERCIALES"**.

In [43]:
```
df.isna().sum()
```

Out[43]:
```
PERIODO               0
NEGOCIO               0
LINEA                 0
MARCA                 0
ARTICULO              0
MMEDICA               0
UNIDADES COMERCIALES  0
dtype: int64
```

No existen valores nulos

Análisis de la variable objetivo

In [44]:
```
# Se procede con análisis de la variable objetivo UC (unidades comerciales)
df['UNIDADES COMERCIALES'].describe()
```

Out[44]:
```
count     64686.000000
mean        810.692314
std        4031.042040
min      -35457.000000
25%           4.000000
50%          34.000000
75%         343.000000
max      261805.000000
Name: UNIDADES COMERCIALES, dtype: float64
```

Al realizar el análisis sobre la columna "UNIDADES COMERCIALES". Los principales hallazgos son:

- Media: 810.7
- Mediana: 34
- Mínimo: -35457
- Máximo: 261.805
- Desviación estándar: 4031.04

La columna "UNIDADES COMERCIALES" muestra una gran dispersión de valores, con una mediana significativamente más baja que la media y una desviación estandar enorme, lo que sugiere la influencia de valores atípicos extremos.

In [46]:
```
plt.figure(figsize=(10, 6))
sns.histplot(df['UNIDADES COMERCIALES'], bins=50, kde=False, color='blue')
plt.title('Histograma de UNIDADES COMERCIALES')
plt.xlabel('UNIDADES COMERCIALES')
plt.ylabel('Frecuencia')
plt.grid(True)
plt.show()
```

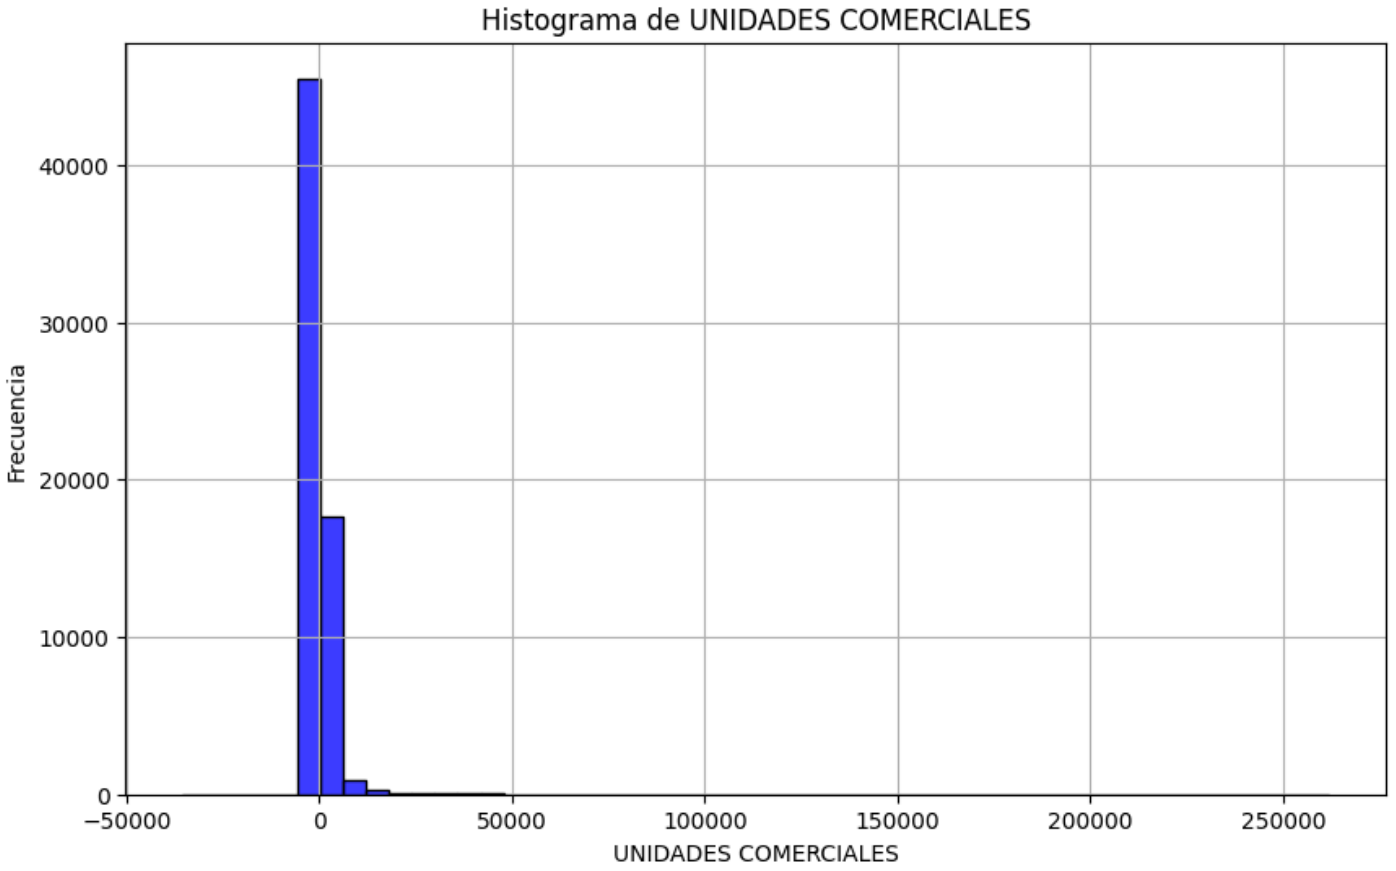

Se observa una gran cantidad de valores cercanos a 0 y algunos valores con cantidades muy altas, lo que indica una distribución con asimetría positiva. Posiblemente se deba a la presencia de valores atípicos.

In [48]:
```
plt.figure(figsize=(10, 6))
sns.boxplot(x=df['UNIDADES COMERCIALES'])
plt.title('Box-plot de Unidades Comerciales')
plt.xlabel('UC')
plt.grid(True)
plt.show()
```

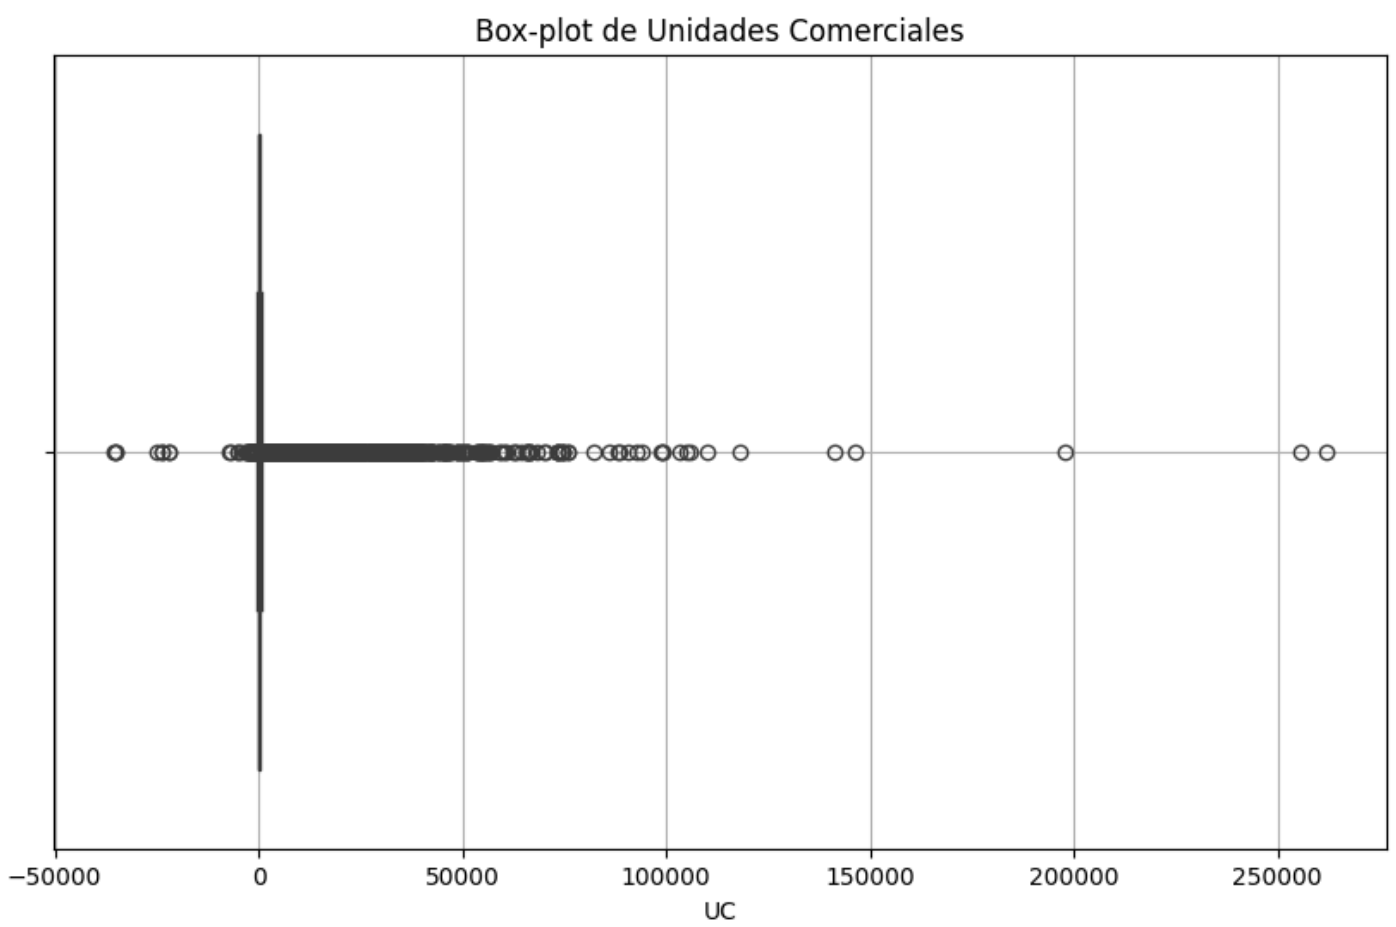

Se observa una gran cantidad de valores atípicos y también se puede observar que existen algunos valores negativos en la variable.

Análisis de valores atípicos

In [ ]:
```
# Crear un gráfico de dispersión con diferentes colores por negocio
sns.scatterplot(x='PERIODO', y='UNIDADES COMERCIALES', hue='NEGOCIO', data=df)
plt.title('Gráfico de Dispersión: PERIODO vs UC por NEGOCIO')
plt.legend(fontsize='small', bbox_to_anchor=(1.05, 1), loc='upper left')
plt.show()
```

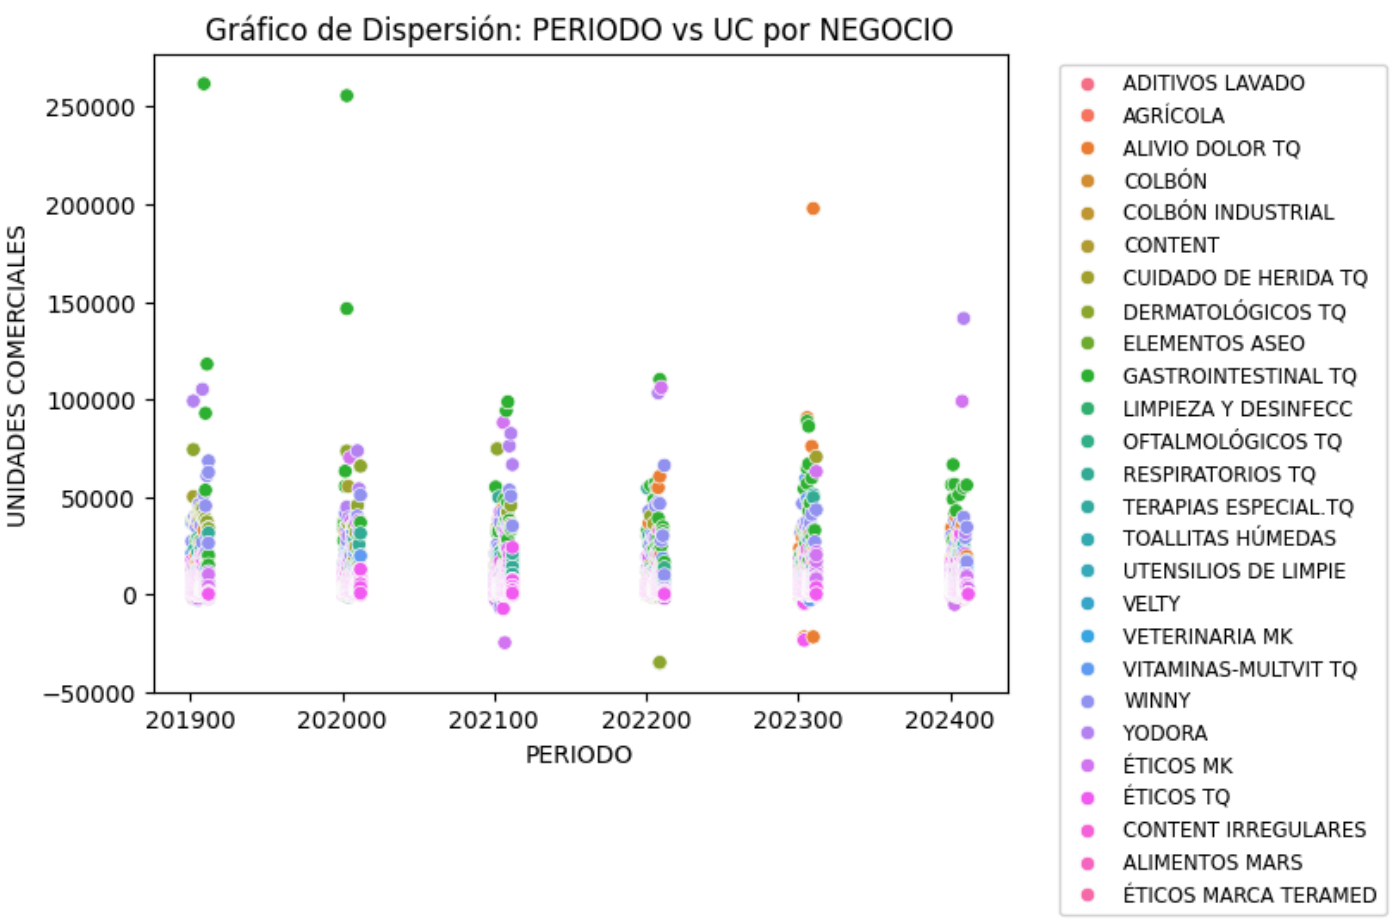

Por petición del cliente, se hace el análisis por negocio, ya que cada negocio tiene sus particularidades. Sin embargo, se observa que valores muy altos predmoninan en varios negocios y se procede mejor a ser un Boxplot para cada uno.

In [54]:
```
plt.figure(figsize=(12, 8))
sns.boxplot(x='NEGOCIO', y='UNIDADES COMERCIALES', data=df)
plt.title('Boxplot de Unidades Comerciales por Negocio')
plt.xlabel('Negocio')
plt.ylabel('Unidades Comerciales')
plt.xticks(rotation=90)
plt.grid(True)
plt.show()
```

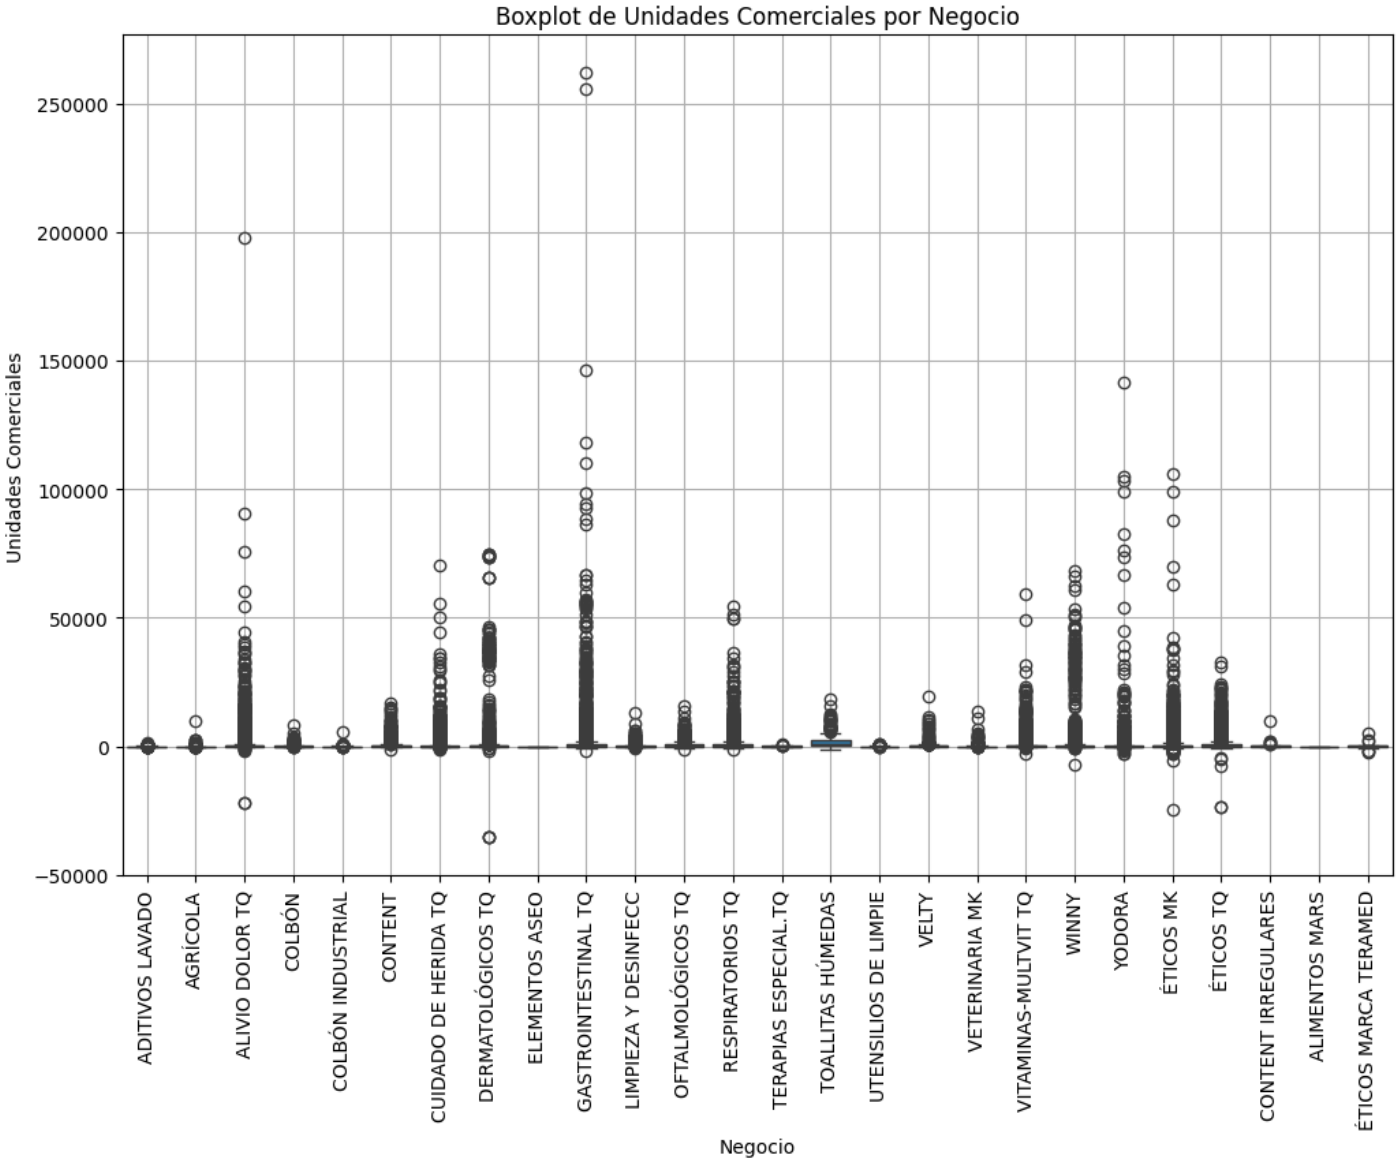

se observa que los negocios que rpesentan más normalidad son:

- Aditivos Lavado
- Agricola y Alimentos
- Colbon y Colbon Industrial
- Content
- Grupo Clorox (Elementos Aseo, Limpieza y Desinfección)
- Eticos Teramed

Sin embargo, estos negocios son aquellos menos significativos (de menor venta) y por ende con menores cantidades de unidades despachadas.